

Análisis de Usuarios de una Plataforma de Streaming

Proyecto Integrador — Minería de Datos 1 | Comisión: Turno Tarde, Nodo | Integrante: Emilio Cabaña | Fecha: Lunes 29 de Junio

1. Contexto y objetivo

El proyecto desarrolla un análisis de datos reproducible sobre un dataset de usuarios de una plataforma de streaming. El objetivo es comprender la calidad inicial de los datos, prepararlos a partir de decisiones justificadas por evidencia, analizarlos a nivel univariado, bivariado y multivariado, y aplicar escalamiento y PCA. No se trata de un proyecto de modelado predictivo, sino de un proceso ordenado de exploración, preparación, análisis e interpretación, con trazabilidad completa del proceso.

2. Dataset y calidad inicial

El dataset contiene 8.160 registros y 8 variables: identificador, edad, plan de suscripción, tiempo de visualización mensual, país, género favorito, fecha de último login y cantidad de tickets de soporte. La inspección inicial reveló múltiples problemas de calidad: 160 identificadores duplicados; edades imposibles (negativas y mayores a 100); valores negativos y valores imposibles de relleno (99999) en el tiempo de visualización; valores imposibles (99, 150) y negativos en los tickets; categorías escritas de formas inconsistentes en plan, país y género; y una columna de fechas con formatos mezclados y valores inválidos (texto, mes 15, fechas futuras).

3. Decisiones de limpieza y preparación

Cada decisión surgió de la evidencia observada y quedó registrada en el log ETL. Se eliminaron duplicados por identificador. Las categóricas se normalizaron a un catálogo canónico (ej. *básico/BASICO/Basic* → Básico). Los valores imposibles por rango y los imposibles de relleno —identificados por su repetición exacta y su separación del resto de la distribución— se trataron como error y se convirtieron en nulo, distinguiéndolos de los outliers reales. La cola alta legítima del tiempo de visualización se acotó por winsorización (IQR $k=3$) en lugar de eliminarse. Las fechas se parsearon y validaron; las no recuperables quedaron como nulo sin imputar, para no introducir datos falsos. El diagnóstico del mecanismo de faltantes mostró que la tasa de nulos en el tiempo de visualización crece con el plan (Básico ~1%, Premium ~11%), un patrón MAR que justifica imputar por la mediana de cada plan en lugar de una mediana global. La retención final fue del 98%.

Registro ETL (resumen)

Paso	Descripción	Filas	Nulos	Ret. (%)
0	Estado original	8160	753	100,0
1	Eliminar duplicados	8000	753	98,0
3	Valores imposibles → nulo	8000	1049	98,0
5	Winsorizar tiempo ($k=3$)	8000	1128	98,0
6	Imputar faltantes	8000	399	98,0

4. Hallazgos del análisis exploratorio

El análisis univariado muestra una base de usuarios de adultos jóvenes (mediana ~33 años) y un consumo típico de ~770 minutos mensuales, con una cola de usuarios muy intensos. Las medidas de forma confirman esta lectura: el consumo presenta asimetría positiva alta y curtosis leptocúrtica, y el coeficiente de variación señala a los tickets como la variable más heterogénea. El análisis bivariado revela la relación más fuerte del dataset: el tiempo de visualización crece de forma clara con el plan, casi duplicándose de Básico (~587 min) a Premium (~1123 min). En cambio, la distribución de planes es homogénea entre países y la preferencia de género es transversal. El análisis multivariado confirma que la edad no se asocia con el consumo, mientras que el plan sí lo separa de manera sistemática. Implicancia: para segmentar por consumo, la variable relevante es el plan y no la edad.

5. Escalamiento y PCA

Sobre las tres variables numéricas (edad, tiempo de visualización y tickets), estandarizadas con StandardScaler, se aplicó PCA. Cada componente principal explica aproximadamente un tercio de la varianza (~33%), lo que indica que las variables son estadísticamente independientes y que no es posible reducir dimensiones sin perder información. En este proyecto, PCA cumple un rol diagnóstico: confirma la ausencia de redundancia entre variables, un resultado válido en sí mismo.

6. Conclusiones y limitaciones

El dataset quedó limpio, auditable y comprendido. El principal factor asociado al consumo es el plan de suscripción. El alcance de las conclusiones está condicionado por la información disponible y por las decisiones documentadas durante el

proceso. La independencia casi total entre variables sugiere un posible origen sintético del dataset, lo que limita la generalización de las relaciones. La imputación reduce levemente la varianza real, y la ausencia de una variable objetivo impide evaluar capacidad predictiva. Como mejoras futuras se plantea incorporar información adicional (variable objetivo, actividad temporal), probar imputación más sofisticada y aplicar técnicas de agrupamiento para detectar segmentos de usuarios.

Enlaces: Repositorio GitHub: *(completar URL)* | Aplicación Streamlit: *(completar URL)*